

Постановка задачи

- сложная графическая сцена
- обнаружение (детекция) текста
- распознавание текста
- **STR $\neq$ OCR**

Мобильный перевод,
навигация роботов, image
captioning, считывание
номерных знаков и т.д.

Фон



Форма



Шум



Структура работы



1. Реализация и исследование модели распознавания CRNN с использованием CTC-loss

2. Реализация и исследование сквозной модели EAST+CRNN (baseline-модель)


3. Реализация и исследование легковесной модификации EAST (MobEAST), основанной на MobileNet

4. Реализация сквозной модели MobEAST+CRNN (MobFOTS) с использованием RoIRotate

Архитектура CRNN

Текст – это последовательность.

Свертка извлекает признаки, а рекуррентные слои используют временные зависимости между этими признаками. Своя функция ошибки (CTC-loss), позволяющая распознавать без сегментации на уровне символов, и bi-directional LSTM-слой, учитывающий контекст в обе стороны.





Исследование CRNN

№	Тип слоя	Ф-я активации	Ядро	Шаг	Кол-во каналов
1	Conv2D	ReLU	3×3	-	64
2	MaxPooling2D	-	2×2	2×2	64
3	Conv2D	ReLU	3×3	-	128
4	BatchNormalization	-	-	-	-
5	MaxPooling2D	-	2×2	2×2	128
6	Conv2D	ReLU	3×3	-	256
7	BatchNormalization	-	-	-	-
8	Conv2D	ReLU	3×3	-	256
9	MaxPooling2D	-	2×2	1×2	256
10	Conv2D	ReLU	3×3	-	512
11	BatchNormalization	-	-	-	-
12	Conv2D	ReLU	3×3	-	512
13	MaxPooling2D	-	2×2	1×2	512
14	Conv2D	ReLU	3×3	-	512
15	Bidirectional	-	-	-	-
16	Bidirectional	-	-	-	-
17	Dense	Softmax	-	-	-

Размер батча	64
Количество эпох	2
Коэффициент скорости обучения α_0	0.001

- алгоритм оптимизации – Adam
- датасет для обучения – Synth 90k
- датасеты для теста – IIIT 5k и SVT
- сравниваем с большим (1000 слов) и малым (100 слов) словарями
- для сравнения вычисляем метрику Левенштейна

Исследование CRNN




Метод	ИИТ 5k	SVT
С большим словарём	92.7	-
С малым словарём	96.2	95.4
Без словаря	73.9	75.1

Архитектура EAST

EAST – быстрая CNN детекции. Извлекает признаки, затем применяет доп. свертки для вычисления карт: оценок (какие пиксели попали в область), углов поворота, расстояний каждого пикселя до 4-х сторон. По картам создаются повернутые прямоугольники, затем находится их пересечение.

Для геометрического лосса, который включается в общую функцию потерь, вводятся метрики IoU и косинус между истинным и предсказанным углами.



Архитектура EAST

$$L = L_s + \lambda_g L_g$$

$$L_s = -\beta Y^* \log \hat{Y} - (1 - \beta)(1 - Y^*) \log(1 - \hat{Y})$$

$$L_g = L_{AABB} + 10 \cdot L_\theta$$


$$L_\theta(\hat{\theta}, \theta^*) = 1 - \cos(\hat{\theta}, \theta^*)$$

$$L_{AABB} = -\log IoU(\hat{R}, R^*) = -\log \frac{|\hat{R} \cap R^*|}{|\hat{R} \cup R^*|}$$

Объединение EAST и CRNN

EAST в итоге генерирует координаты каждого угла для каждого прямоугольника, а CRNN использует эту информацию для распознавания.

- базовая модель PVANet заменена на ResNet50
- теперь скорость обучения линейно снижается в процессе обучения



Модифицируем EAST

- акцент на ускорение инференса
- трансферное обучение над MobileNet
- 13 блоков с точечной сверткой и сверткой в глубину
- L2-регуляризация ядра
- выводы точечных сверток извлекаются в блоках 2, 5, 11 и 13
- создаются карты оценок, геометрии и углов путем применения свертки 1x1 с 1, 4 и 1 фильтрами, соответственно

$$L' = L + \lambda \sum_{i=1}^N \sum_{j=1}^{p_i} (\alpha_i^j)^2$$

i – номер слоя, α – вектор параметров

Исследование MobEAST

- Алгоритм оптимизации – Adam
- Экспоненциальное затухание скорости обучения (sheduler)
- Будем относить объект к определенному классу, используя пороговое значение для IoU
- Метрики оценивания – Precision, Recall, F-score
- Датасеты для обучения – ICDAR15 (1000 изображений) и ICDAR13 (230 изображений)
- Изображения сопровождаются txt-файлом с координатами углов областей и истинным текстом
- Датасет для валидации – ICDAR15 (500 изображений)
- Для увеличения тренировочного датасета используется аугментация



Исследование MobEAST

Модель обучалась на всех параметрах (без замораживания базовой модели)

Точность получилась близкой к оригинальной, однако у мод. модели меньше параметров

Метод	Precision	Recall	F-score	Кол-во параметров
EAST	0.847	0.773	0.808	24.2 млн.
Мод. EAST	0.841	0.681	0.753	3.6 млн.

Размер батча	4
Количество эпох	400
Коэффициент скорости обучения α_0	0.0001
Коэффициент затухания λ	0.94


Исследование MobEAST

Время работы модели значительно выросло, что показывают исследования на различных размерах изображений. Для каждого эксперимента использовались одни и те же 500 тестовых изображений, изменялся лишь размер.

Ширина, пк.	Высота, пк.	Время для EAST, сек.	Время для мод. EAST, сек.	Прирост скорости, %
320	180	0.089	0.052	71
640	360	0.199	0.056	255
960	540	0.231	0.084	175
1280	720	0.242	0.115	110
1600	900	0.242	0.127	90

Исследование MobEAST

Хотя модель и обучалась на англоязычных текстах, она также способна обнаруживать надписи на кириллице.



Архитектура MobFOTS

Добавляем компонент распознавания к ранее модифицированной модели.

После преобразования батча из N изображений, их общие свертки трансформируются с помощью RoIRotate и передаются на вход CRNN, аналогично использующей CTC-loss.

Исследование не проводилось из-за недостатка вычислительных ресурсов.

№	Тип слоя	Ф-я активации	Ядро	Шаг	Кол-во каналов
1	Conv2D	ReLU	3×3	-	64
2	Conv2D	ReLU	3×3	-	128
3	BatchNormalization	-	-	-	-
4	MaxPooling2D	-	2×2	2×2	-
5	Conv2D	ReLU	3×3	-	256
6	Conv2D	ReLU	3×3	-	256
7	BatchNormalization	-	-	-	-
8	Dense	ReLU	-	-	-
9	Bidirectional	-	-	-	-
10	Dropout	-	-	-	-
11	Dense	Softmax	-	-	-

Заключение

Основной результат работы – новая модель MobEAST, способная выделять области с текстом с очень высокой скоростью, при этом сохраняя state-of-the-art точность.

Направления дальнейшей работы:

- дообучение MobFOTS
- переход от прямоугольных областей к более гибким формам
- адаптирование моделей к работе с другими языками (трансферное обучение)
- дополнительная работа над алгоритмом оптимизации
- внедрение моделей в мобильные приложения
- исследование методов бинаризации в контексте данной задачи